



CentraleSupélec

Mise en avant des facteurs de risques du cancer du sein

FONTENEAU ROMAIN
BOUAINOUCHE WALID
VENET CORENTIN
HAXAIRE CLÉMENCE



CentraleSupélec

1 Introduction

Le cancer du sein est aujourd'hui la première cause de cancer chez la femme. Comprendre les facteurs de risques associés à cette maladie revêt une importance cruciale pour la prévention, le dépistage précoce et les interventions thérapeutiques. Cette étude propose un examen des facteurs de risque du cancer du sein, en se basant sur des recherches et des données scientifiques récentes. Une analyse des données de l'EDS de l'APHP nous permettra de comparer les facteurs de risque dans la littérature avec ceux identifiés dans notre étude.

Parmi les facteurs de risque identifiés dans la littérature, les antécédents familiaux de cancer du sein sont considérés comme l'un des facteurs prédisposants les plus importants. Des altérations génétiques, telles que les mutations des gènes BRCA1 et BRCA2, sont associées à un risque significativement accru de développer un cancer du sein.

D'autres facteurs de risque non héréditaires sont également évalués. L'âge est un déterminant crucial, avec une incidence plus élevée chez les femmes plus âgées. Les facteurs hormonaux, tels que des niveaux élevés d'œstrogènes et de progestérone, jouent un rôle clé, notamment en relation avec la période reproductive, la ménopause, l'utilisation de contraceptifs hormonaux et la thérapie hormonale substitutive. De plus, l'obésité, la sédentarité et une alimentation déséquilibrée sont des facteurs de risque modifiables qui peuvent influencer l'incidence du cancer du sein.

La consommation excessive d'alcool et le tabagisme sont enfin des facteurs comportementaux qui peuvent également augmenter le risque de développer la maladie.

2 Méthodologie

Dans un premier temps, nous avons exploré les données à notre disposition pour établir quelques statistiques descriptives telles que la taille de la population disponible, le nombre de patients atteints du cancer du sein, le nombre d'hopitaux inclus dans l'étude ou encore la date d'inclusion des patients dans l'étude.

Nous avons répertorié les différentes conditions présentes dans les tables de données et avons identifié grâce à Aide au codage à quel diagnostic elles correspondaient. Nous les avons ensuite regroupé par catégories plus générales : cancer du sein, cancer du colon, cancer du poumon, maladie de Parkinson, tabac, diabète, hypertension, antécédents familiaux de tumeur maligne du sein, VIH, alcool, consommation de substances psychoactives.

Nous avons alors identifié les personnes atteintes de cancer du sein et constaté qu'aucun homme ne l'était dans les données. Nous avons par conséquent restreint notre étude aux femmes.

Une fois la population d'étude choisie (les femmes), nous avons cherché à l'épurer grâce au processus de déduplication pour regrouper les données correspondant à un même patient et mieux les analyser. Pour effectuer cette déduplication, deux options s'offraient à nous : être déterministe ou probabiliste. Nous avons opté pour une déduplication probabiliste avec un seuil de 90% qui offre la meilleure épuration des doublons. En effet, c'est ce seuil critique qui correspond à un taux de ressemblance idéal, l'association de deux patients identiques n'étant plus efficace si le seuil choisi est trop important.

Pour identifier les facteurs de risque du cancer du sein, nous avons donc à notre disposition les codes inscrits par les médecins et regroupés en catégories plus générales (tabac, Maladie de Parkinson, etc.). Cependant, ces codes ne sont pas suffisants car certaines conditions sont mal renseignées, notamment le tabac. Pour palier cette absence d'information du côté des codes, nous avons procédé à une lecture des comptes-rendus médicaux, et avons listé les mots relatifs au statut "fumeur" dans ces notes. Grâce à la mise en place d'un algorithme NLP, nous avons pu déterminer les fumeurs de notre étude.

Dans une dernière phase de pré-processing, nous avons également intégré à notre étude certaines caractéristiques biologiques des patients, qui peuvent dans certains cas impliquer une augmentation du risque d'être atteint du cancer du sein.

Après une ultime vérification de la validité de nos données transformées, la phase de pré-processing est terminée et nous avons alors réalisé une étude statistique. Pour cela, nous avons comparé deux populations de patientes : celles atteintes du cancer du sein et celles qui ne le sont pas. Pour chaque facteur, nous avons alors réalisé un test statistique afin de déterminer ceux qui pouvaient se présenter comme un facteur de risque, les tests statistiques permettant de quantifier l'écart entre la population de contrôle et la population atteinte du cancer du sein concernant chaque facteur. Pour cela, nous avons mis en place 2 types de tests : le test de chi-2 pour les données qualitatives (patient touché par le diabète ou non, alcoolique ou non,...) et test de Student pour les données quantitatives (age, caractéristiques biologiques).

3 Résultats et analyse

Statistiques descriptives :

Taille de la population disponible : 16 168 personnes dont 10 235 femmes et 5 933 hommes

Hopitaux et visites : 4 hopitaux pour environ 4 000 visites chacun

1 seul logiciel est utilisé par les médecins donc il ne manque aucune naissance.

Algorithme NLP :

La vérification de l'annotation réalisé pour 100 textes a donné une performance de l'algorithme NLP de 87%.

Facteurs de risque :

Les résultats de l'analyse statistique sont référencés dans le tableau ci dessous :

	cancer_sein	Pas de cancer du sein	Cancer du sein	p_value
person_id	count	5625	4106	
age	moyenne_ecarttype	50.59 (27.47)	78.51 (13.99)	0.0
alcool	prevalence	3.7	10.72	0.0
antécédents	prevalence	5.1	29.1	0.0
cancer_colon	prevalence	24.12	0.0	0.0
cancer_poumon	prevalence	24.14	0.0	0.0
diabète	prevalence	2.42	4.55	0.0
hypertension	prevalence	12.71	32.64	0.0
parkinson	prevalence	51.27	0.0	0.0
sida	prevalence	0.02	0.0	1.0
substances	prevalence	2.36	10.2	0.0
tabac	prevalence	51.8	55.94	0.000058
bmi	moyenne_ecarttype	20.56 (2.53)	24.98 (1.99)	0.0
crp	moyenne_ecarttype	4.54 (0.35)	4.51 (0.3)	0.000004
hb	moyenne_ecarttype	12.89 (1.51)	12.97 (1.5)	0.005319
urea	moyenne_ecarttype	3.6 (0.67)	4.19 (0.46)	0.0

Tableau récapitulatif de l'impact des facteurs de risque

Tout d'abord, on remarque que la p-value concernant le facteur VIH est très importante mais nous avons au cours de notre étude réalisé que le nombre de patients atteints du sida dans nos données était de 2 donc cette population est trop faible pour en tirer des conclusions cohérentes.

Par ailleurs, pour les autres facteurs, les p-value sont très faibles. Ceci est cohérent avec le grand effectif de la population (la p-value étant inversement proportionnelle à la taille de la population). Cela signifie alors qu'il y a une différence significative entre les deux populations pour les différents facteurs de risque, car la p-value est inférieure à 0,05.

Enfin, concernant le tabagisme, les données sont biaisées car notre population de personnes saines correspond aux patients qui se rendent à l'hôpital et donc qui sont déjà prédisposés à la consommation de tabac, d'où le pourcentage élevé de fumeurs. On remarque tout de même avec la p-value que les deux populations sont significativement différentes et donc que le tabac a un réel impact sur la détection du cancer du sein.

4 Conclusion

Les facteurs de risque majeurs identifiés dans notre étude sont le tabagisme, la consommation d'alcool, les antécédents familiaux, le diabète, l'hypertension, la consommation de substances psychoactives et l'âge.

Néanmoins, l'utilisation de données médicales provenant du personnel dont la priorité n'est pas nécessairement la saisie engendre des risques d'erreurs et d'omissions. Nos hypothèses selon lesquelles l'absence de mention d'un statut (de diabétique par exemple) signifie que le patient ne l'est pas peuvent être remises en question. De plus, le calcul du seuil de déduplication probabiliste, bien que réfléchi, reste contestable, et d'autres méthodologies pourraient donner des résultats différents mais acceptables. Il est important de noter que notre algorithme NLP pour la détection du statut de fumeur ou non-fumeur présente un score de 0.87, ce qui est perfectible. Enfin, notre étude, bien qu'elle se base sur un échantillon considérable et varié, représentatif de la population, est limitée par sa focalisation sur les données disponibles et jugées pertinentes, excluant ainsi certains facteurs potentiellement à risque.

Malgré les erreurs potentielles dans la base de données initiale, il est extrêmement difficile d'obtenir une base de données parfaitement exhaustive dans le domaine de la santé. Nous avons entrepris des étapes de déduplication et d'analyse des notes pour améliorer la qualité de notre base de données. En conclusion, les facteurs de

risque principaux identifiés correspondent à l'état de l'art, qui met en évidence le tabagisme, l'alcoolisme, l'âge et les antécédents familiaux comme des facteurs de risques importants. Cependant, en raison de la complexité du corps humain, notre étude ne pouvait pas prendre en compte tous les facteurs de risque mentionnés dans la littérature, tels que les facteurs hormonaux, l'obésité, la sédentarité et l'alimentation déséquilibrée. Une analyse exhaustive nécessiterait l'exploration de milliers, voire de millions de variables.

5 Références

Lymphome malin non hodgkinien du sein et VIH :

<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5516662/>

Profil épidémiologique et anatomopathologique du cancer de sein au CHU Ibn Rochd, Casablanca :

<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7648477/>

Hypertension and the risk of breast cancer in Chilean women :

case-control study : <https://pubmed.ncbi.nlm.nih.gov/23317264/>

Tobacco and alcohol consumption in women treated for breast cancer in a department of surgical oncology :

<https://pubmed.ncbi.nlm.nih.gov/34756596/>

Global Increase in Breast Cancer Incidence : Risk Factors and Preventive Measures :

<https://pubmed.ncbi.nlm.nih.gov/35480139/>

Rating the Risk Factors for Breast Cancer :

<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC1514477/>