

Statistique avancées

Devoir maison

A rendre au plus tard le 15 mai à 18h

Le devoir maison donne lieu à un compte-rendu rédigé à effectuer en binôme, à rendre pour le 15 mai à 18h sur Edunao.

- La qualité de la rédaction sera prise en compte.
- Commenter les résultats obtenus. Inclure les graphiques pertinents dans le corps du texte.
- Les résultats doivent être justifiés
- Le compte-rendu est à remettre sous forme d'un **pdf** contenant le compte-rendu et d'un fichier texte **.R** contenant les lignes de codes. Les fichiers seront nommés avec vos noms, soit **NOM1-NOM2.pdf** et **NOM1-NOM2.R**

Exercice 1

On considère le jeu de données **Ozone** où on cherche à expliquer la concentration maximale en ozone relevée sur une journée (variable **maxO3**) par d'autres variables essentiellement météorologiques. Vous trouverez le jeu de données **Ozone** sur Edunao. Cet exercice est à réaliser avec le logiciel **R**.

1. Faire une étude descriptive des données et la commenter.
2. Faire tourner un modèle linéaire sur ces données.
3. Expliquer ce que fait la fonction **stepAIC**. On rappellera la formule du critère utilisé par défaut et on détaillera la méthode.
4. Quel est le modèle choisi par le critère BIC. Commenter.
5. Faire une recherche exhaustive, grâce à la fonction **regsubsets** du package **leaps**. Expliquer ce que fait cette fonction.
6. Expliquer la différence entre la notion de variable dans **stepAIC** et dans **regsubsets**.
7. Sur une fenêtre partagée en quatre, faire afficher les graphes associés à la fonction **regsubsets** dans les cas **bic**, **Cp**, **adjr2**, **r2** avec un titre pour chaque graphe et un titre général. Commenter.
8. Donner l'expression du modèle de plus faible BIC et préciser son ajustement.
9. Etudier la validité du modèle choisi par le critère BIC.
10. Mettre en place une procédure permettant de calculer l'erreur de prédiction de ce même modèle.

Exercice 2

Soit $Y = (Y_1, \dots, Y_n)^T$, $X = (x_{i,j})_{1 \leq i \leq n, 1 \leq j \leq p}$ non aléatoire vérifiant

$$Y = X\beta^* + \varepsilon,$$

avec $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$ et $\beta^* = (\beta_1^*, \dots, \beta_p^*)^T \in \mathbb{R}^p$.

1. Dans quel(s) cas la matrice de covariables X peut-elle être singulière ?
2. Montrer que le problème de minimisation

$$\min_{\beta \in \mathbb{R}^p} \left\{ \sum_{i=1}^n (Y_i - X_i \beta)^2 + \lambda \|\beta\|_2^2 \right\}, \quad (1)$$

où $\|\beta\|_2^2 = \sum_{j=1}^p \beta_j^2$, admet une unique solution que l'on explicitera.

3. Montrer que toute solution du problème d'optimisation sous contrainte suivant

$$\min_{\beta \in \mathbb{R}^p, \|\beta\|_2 \leq M_\lambda} \left\{ \sum_{i=1}^n (Y_i - X_i \beta)^2 \right\} \quad (2)$$

avec $M_\lambda = \|(X^T X + \lambda I_p)^{-1} X^T Y\|$ est aussi solution du problème (1). En déduire l'unique solution du problème (2).

4. Propriétés de l'estimateur obtenu à la question 2 :
- (a) Calculer le biais de l'estimateur. Commenter.
 - (b) Calculer la variance de l'estimateur. Commenter.
5. Quel est l'intérêt de considérer le problème de minimisation (1) par rapport au problème des moindres carrés classiques ? Dans quel(s) cas est-il intéressant d'utiliser cette méthode ? Quelles sont ses avantages et ses inconvénients ?