

TP2: Modèle linéaire

Sarah Lemler

Mettre en place l'environnement de travail:

```
setwd("Mon répertoire") # à personnaliser
rm(list=objects())
graphics.off()
```

1. Régression linéaire

On dispose d'un jeu de données réelles de 97 patients atteints d'un cancer de la prostate sur le point de subir une prostatectomie radicale. On dispose des variables suivantes : **lcavol** le logarithme du volume tumoral (log cancer volume), **lweight** le logarithme du poids de la prostate, **age** l'âge du patient, **lbhp** le logarithme de la quantité d'hypertrophie bénigne (augmentation du volume de la prostate), **svi** l'invasion des vésicules séminales (1=Yes, 0=No), **lcp** logarithme de la pénétration capsulaire, **gleason** le score de Gleason, **pgg45** pourcentage des scores de Gleason 4 ou 5, **lpsa** le logarithme d'antigènes prostatiques spécifiques (Log PSA)¹. Lorsque la concentration de PSA dans le sang est plus élevée que la normale, cela peut indiquer la présence d'un cancer de la prostate. Nous allons étudier dans la suite le lien entre l'antigène prostatique spécifique (PSA) et les 8 autres variables cliniques.

1.1 Acquérir les données

Charger les données à partir du fichier Prostate.txt que vous aurez préalablement téléchargé sur Edunao.

```
Prostate<- # à compléter
```

Afficher les premières lignes et vérifier que le dataframe obtenu comporte 97 observations et 9 variables quantitatives.

1.2 Analyse uni- et bi-variée

Commenter les analyses univariées et bivariées suivantes :

```
summary(Prostate)
pairs(Prostate)
cor(Prostate)

library(corrplot)
corrplot(cor(Prostate))
```

¹Stamey, Thomas A., et al., Prostate specific antigen in the diagnosis and treatment of adenocarcinoma of the prostate. II. Radical prostatectomy treated patients. The Journal of urology (1989)

1.3 Modéliser

Après cette étude descriptive préliminaire, quel modèle proposer?

1.4 Calcul à la main

1. Identifier dans le code suivant les éléments vus dans le cours pour l'estimation d'une régression linéaire.

```
X=as.matrix(Prostate[,1:8])
X=cbind(intercept=1,X)
Y=as.matrix(Prostate$lpsa,ncol=1)
beta.est=solve(t(X)%*%X)%*% t(X)%*%Y
n=length(Y)
p=ncol(X)
sigma.est=sqrt(sum( (X%*%beta.est -Y)^2 )/(n-p))
V= solve(t(X)%*%X) *sigma.est^2
stddev=sqrt(diag(V))
```

2. Pour chaque composante, calculer la statistique et la p-valeur du test de nullité. Interpréter.
3. Calculer l'estimation du logarithme d'antigènes prostatiques spécifiques pour les valeurs de covariables de la deuxième observation, puis pour l'ensemble des observations.

1.5 Estimer: fonction lm

Le modèle linéaire peut être directement estimé par la fonction **lm** (linear model), dont le premier argument indique le modèle sous la forme **y~formule** où **y** est le nom de la variable réponse et **formule** les noms des variables explicatives concaténés par des **+**. On peut remplacer formule par **.** pour mentionner que toutes les variables du dataframe (hormis la réponse) sont explicatives.

```
# lm(lpsa ~ lcavol + lweight + age + lbph + svi + lcp + gleason + pgg45, data=Prostate)
model8=lm(lpsa~.,data=Prostate)
summary(model8)
names(model8)
model8$coef
# à compléter !
```

1. Faire la correspondance entre les informations calculées à la main et certaines informations rendues par **summary**. L'objet créé par la fonction **lm** comporte plusieurs composantes que l'on peut extraire par l'opérateur **\$**. La fonction **names** liste le noms des composantes disponibles. Les identifier et les utiliser pour caractériser les sorties de **summary**.
2. Calculer l'estimation ponctuelle du logarithme d'antigènes prostatiques spécifiques pour chaque observation, comparer avec la réponse à la question 3 de la partie 1.4 et avec les résultats de la fonction **predict**.

```
predict(model8)
```

1.6 Intervalle de confiance

1. Calculer un intervalle de confiance de niveau 95% pour chacun des paramètres du modèle (**vcov**, **qt**). Comparer avec les résultats de la fonction **confint**.

2. Prédire par intervalle de confiance de niveau 95% un logarithme d'antigènes prostatiques spécifiques moyen pour **lcavol=0.75**, **lweight=3.43**, **age=62**, **lbph=-1.39**, **svi=0**, **lcp=-1.39**, **gleason=6**, **pgg45=0**. Retrouver ce résultat en utilisant la fonction **predict**.
3. Comparer avec un intervalle de prévision de niveau 95% pour une valeur individuelle de logarithme d'antigènes prostatiques spécifiques, sous les mêmes conditions et commenter.

1.7 Tester et sélectionner des variables

1. Retrouver par le calcul la statistique de Fisher du modèle iid contre le modèle complet. La régression est-elle globalement significative ?

```
SCRH1= sum(model8$resid^2 )
SCRH0= # à compléter
```

La fonction **anova** permet de faire des tests (de Fisher) de modèles emboîtés. Les arguments sont les deux modèles en compétition. Par exemple, l'instruction suivante fait le test de significativité globale.

```
anova(lm(y~1,data=df),model8)
```

2. Tester le modèle contenant uniquement la variable **lcavol** contre le modèle complet **model8**.
3. Retrouver "à la main" la valeur de la statistique de Fisher
4. Quel modèle choisir ? L'enregistrer dans la variable **lmf**.

1.8 Valider

1. Repérer les différents graphiques générés par les commandes suivantes, et les interpréter.

```
#
par(mfrow=c(2,2), oma=c(0,0,2,0))
#
plot(lmf$fitted,Prostate$lpsa,main="à compléter")
abline(0,1)
#
plot(lmf$fitted,lmf$residuals,main="à compléter")
library(MASS) # pour la fonction stdres
points(lmf$fitted,stdres(lmf), col=2,pch=2 )
points(lmf$fitted,stdres(lmf),col=3,pch=3)
abline(h=2)

abline(h=-2)
legend("bottomright",c("à compléter", "à compléter", "à compléter"),col=1:3, pch=1:3,
      cex=0.5)
#
qqnorm(stdres(lmf),main="à compléter")
qqline(stdres(lmf))
#
title(main="Validation en régression linéaire multiple", outer=TRUE)
```

2. Interpréter également les graphiques générés par la fonction plot.

```
par(mfrow=c(2,2), oma=rep(0,4))
plot(lmf)
```

3. Quels modèles sont sélectionnés avec les critères AIC et BIC ? Commenter.

2. Une analyse de covariance²

Lors d'une perfusion faite à l'aide d'un pousse seringue, l'occlusion de la ligne de perfusion interrompt l'administration du produit. La pression dans le système de perfusion augmente alors, jusqu'à atteindre un niveau qui met en alarme le perfuseur et le stoppe. On étudie le temps écoulé avant le déclenchement de l'alarme (délai en secondes) pour quatre systèmes S1, S2, S3 et S4. Chaque système est soumis à 8 débits (ml/h) différents.

2.1 Acquérir les données

Les données se trouvent dans le fichier **perfusion.data** que vous pouvez trouver sur Edunao (pensez à le mettre dans votre répertoire de travail). Acquérir les données. Vérifier qu'il y a 96 observations et 3 variables.

```
rm(list=objects()); graphics.off()
# setwd("~/TD") # à personnaliser
perf=read.table("perfusion.data",header=TRUE, row.names=1,skip=1)
```

2.2 Analyser

1. Combien y a-t-il d'observations par système et par débit? Quel est le temps moyen écoulé par système et par débit?
2. Représenter graphiquement les données et commenter.

```
library(lattice)
xyplot(delai~debit|systeme,data=perf)
```

3. Indiquer pourquoi il peut être pertinent de travailler avec la variable **invdebit=1/debit**. L'ajouter au tableau de données.

```
perf$invdebit=1/perf$debit
```

On poursuit maintenant l'étude avec la variable **invdebit**.

4. Le code suivant représente, sur la même figure, toutes les observations (**invdebit**, **delai**), en donnant des attributs de couleur et de point différents suivant les systèmes. Modifier le code pour nommer l'axe des abscisses et celui des ordonnées, attribuer un titre au graphique, tracer la légende.

```
plot(perf$invdebit,perf$delai,col=c(1:4),pch=c(1:4))
# à compléter
```

2.3 Modéliser

Après cette étude descriptive préliminaire, quel modèle proposer?

2.4 Estimer

```
Mg=lm(delai~systeme*invdebit,data=perf)
summary(Mg)
anova(Mg)
```

²Christine Keribin

1. Commenter les sorties de la fonction **lm**: quelles sont les conditions d'identifiabilité utilisées par **R**? Quelles sont les valeurs estimées de paramètres et que représentent-elles?
2. Tracer les droites d'ajustement.
3. Comparer avec le code suivant:

```
Mgbis=lm(delai~systeme+systeme:invdebit,data=perf)
summary(Mgbis)
anova(Mgbis)
```

2.5 Valider

Quelle est la valeur du coefficient de détermination? Tracer le graphe des résidus studentisés, le graphe quantile/quantile. Effectuer un test de Shapiro-Wilks. Validez-vous le modèle?

à compléter

2.6 Tester des sous-modèles

Tester le sous-modèle correspondant à l'hypothèse d'égalité des droites de régression : écrire les hypothèses du test (en fonction des paramètres), la statistique de test, votre règle de décision et votre conclusion. Effectuer directement le calcul, puis retrouver le résultat avec la commande `anova`.

```
# directement
M0=lm() # à compléter
SCRO=
SCRg=
# commande anova
anova(M0,Mg)
```

Tester de la même façon chacun des sous-modèles suivants :

- M2: même ordonnée à l'origine, des pentes différentes,
- M3: égalité des pentes,
- M4: droite S1 identique à S4, les autres différentes,
- M5: droite S1 identique à S4, les ordonnées à l'origine de S2 et S3 identiques.

```
M2=lm(delai~systeme:invdebit,data=perf);summary(M2)
anova(M2,Mg)
M3=lm(delai~systeme+invdebit,data=perf);summary(M3)
anova(M3,Mg)
perf$syst=perf$systeme
perf$syst=perf$systeme
perf$systeme14[perf$systeme=="S4"]="S1" #on change tous les levels "S4" en "S1"
M4= lm(delai~syst*invdebit,data=perf);summary(M4)
# à compléter pour M5
```

Quel modèle retenir? Ne pas oublier de le valider ! Représenter graphiquement l'ajustement en superposant chaque droite ajustée sur le graphe des observations.

2.7 Intervalle de confiance

Sur la base du modèle retenu précédemment, calculer un intervalle de confiance de la différence des temps d'alarme entre S2 et S3 quand le débit vaut 5 ml/h.