

DM de statistiques avancées



Membres du groupe : Lucas Lacampagne, Corentin Venet

Table des matières

1	Exercice 1	1
1.1	Question 1	1
1.2	Question 2	2
1.3	Question 3	3
1.4	Question 4	4
1.5	Question 5	4
1.6	Question 6	5
1.7	Question 7	6
1.8	Question 8	8
1.9	Question 9	9
1.10	Question 10	10
2	Exercice 2	11
2.1	Question 1	11
2.2	Question 2	11
2.3	Question 3	11
2.4	Question 4.a	11
2.5	Question 4.b	12
2.6	Question 5	12

1 Exercice 1

1.1 Question 1

Concernant l'étude descriptive des données, on peut tout d'abord utiliser la fonction **summary** pour obtenir une première approche des données mises à disposition grâce à une analyse univariée (afin notamment de les trier comme ci-joint dans le fichier R).

Par la suite, on utilise une approche bivariée par l'intermédiaire de la fonction **pairs**. On obtient alors la figure suivante :




FIGURE 1 – Graphiques de dispersion des variables 2 à 2

On peut également utiliser la matrice de corrélation (et donc la fonction **corrplot**) pour les variables quantitatives afin de mettre en évidence les relations entre les variables quantitatives. On obtient la figure suivante :




FIGURE 2 – Tracé schématique de la matrice de corrélation des variables quantitatives

On remarque dans un premier temps que certaines variables semblent davantage corrélées à *maxO3* que d'autres, notamment *T9*, *T12* et *T15* dans la première analyse ainsi que *Ne9*, *Ne12*, *Vx9* et *maxO3v* d'après la deuxième figure.

1.2 Question 2

En faisant tourner un modèle linéaire sur ces données (fonction **lm**), on obtient les résultats suivants :

```

Call:
lm(formula = maxO3 ~ ., data = Ozone)

Residuals:
    Min       1Q   Median       3Q      Max
-51.814  -8.695  -1.020   7.891  40.046

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  16.26536   15.94398   1.020  0.3102
T9             0.03917    1.16496   0.034  0.9732
T12            1.97257    1.47570   1.337  0.1844
T15            0.45031    1.18707   0.379  0.7053
Ne9           -2.10975    0.95985  -2.198  0.0303 *
Ne12          -0.60559    1.42634  -0.425  0.6721
Ne15          -0.01718    1.03589  -0.017  0.9868
Vx9            0.48261    0.98762   0.489  0.6262
Vx12           0.51379    1.24717   0.412  0.6813
Vx15           0.72662    0.95198   0.763  0.4471
maxO3v         0.34438    0.06699   5.141 1.42e-06 ***
ventNord       0.53956    6.69459   0.081  0.9359
ventOuest     5.53632    8.24792   0.671  0.5037
ventSud       5.42028    7.16180   0.757  0.4510
pluieSec      3.24713    3.48251   0.932  0.3534
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 14.51 on 97 degrees of freedom
Multiple R-squared:  0.7686,    Adjusted R-squared:  0.7352
F-statistic: 23.01 on 14 and 97 DF,  p-value: < 2.2e-16

```

FIGURE 3 – Résultats du modèle linéaire

Ainsi, il semblerait que les variables les plus significatives soient *Ne9* et *maxO3v* (p-valeurs très faibles). Avec l'ensemble de ces variables, le résultat semble déjà plutôt satisfaisant car 77% de la variable *maxO3* est expliqué par ses covariables (multiple R-squared).

1.3 Question 3

La fonction **stepAIC** permet de réaliser un choix de modèle à partir du critère AIC (Akaike Information Criterion) ou du critère BIC (Bayesian Information Criterion) qui consiste à choisir le modèle qui correspond à un minimum d'une fonction dépendante de la vraisemblance.

Par défaut, le critère utilisé est le critère AIC qui correspond à la minimisation de : $AIC(M_q) = -2\log(L(M_q)) + 2q$ avec M_q le modèle choisi en cas de sous-paramétrisation et le modèle réel en cas de sur-paramétrisation. De plus, d'après la documentation, la direction empruntée par la fonction **stepAIC** s'il n'y a pas d'argument *scope* est 'backward'. Cela signifie qu'on part du modèle complet et qu'on enlève successivement la variable la moins influente selon le critère AIC. On s'arrête dès que le fait de retirer une nouvelle variable diminue les performances du modèle.

1.4 Question 4

En utilisant la fonction **stepAIC**, spécifiée avec la critère BIC et dans la direction 'both', c'est-à-dire 'forward' et 'backward' à la fois, on obtient le modèle linéaire suivant :

Coefficients:				
(Intercept)	T12	Ne9	Vx9	max03v
12.6313	2.7641	-2.5154	1.2929	0.3548

FIGURE 4 – Résultats du modèle linéaire avec le critère BIC

Ainsi, il semble que le modèle linéaire puisse se réduire à 4 covaribles (plus l'intercepte). Si on s'intéresse aux intervalles de confiance des paramètres obtenus, on a :

	2.5 %	97.5 %
(Intercept)	-9.17664531	34.439265
T12	1.82344439	3.704736
Ne9	-3.85518617	-1.175618
Vx9	0.09910521	2.486609
max03v	0.24007499	0.469588

FIGURE 5 – Intervalles de confiance des paramètres du modèle linéaire

On remarque alors que pour les 4 paramètres, 0 n'est pas dans l'intervalle de confiance et donc ces 4 paramètres sont significatifs.

1.5 Question 5

Une recherche exhaustive avec la fonction **regsubsets** correspond à la recherche de toutes les combinaisons possibles de variables explicatives pour construire des modèles de régression. Elle examine chaque sous-ensemble de variables qui mène à l'obtention in fine du modèle qui minimise un certain critère.

La recherche est réalisée pour plusieurs critères, les plus courants étant le critère d'information bayésien (BIC), le critère Cp de Mallows, le coefficient de détermination ajusté (adjR2) et le coefficient de détermination ordinaire (R2).

1.6 Question 6

La différence entre **stepAIC** et **regsubsets** correspond à la méthode de sélection des variables.


En effet, **stepAIC** est une fonction qui utilise une approche itérative, ajoutant ou retirant progressivement des variables du modèle. Elle compare des modèles 2 à 2, basé sur des critères d'information tels que l'AIC ou le BIC pour sélectionner celui qui minimise le critère choisi. Cette méthode est dynamique, car elle modifie le modèle à chaque étape en fonction de l'impact de chaque variable sur le critère sélectionné.

D'autre part, **regsubsets** réalise une recherche exhaustive de toutes les combinaisons possibles de variables explicatives. Contrairement à **stepAIC**, elle considère simultanément toutes les combinaisons de variables et évalue chaque modèle avec des critères tels que le BIC, le Cp de Mallows, le adjR2 ou le R2. Cette méthode est statique, car elle explore toutes les combinaisons sans modifier le modèle au fil du processus.


1.7 Question 7

Voici les résultats obtenus par les commandes du fichier R :

Critères de sélection de modèles



Nombre de covariables idéal



On remarque comme attendu que les critères de R^2 et $\text{adj}R^2$ sont croissants avec le nombre de variables. En revanche, pour les critères BIC et Cp, le nombre idéal de covariables est 4 (auquel s'ajoute l'intercepte). D'après la première figure, ces variables sont : $T12$, $Ne9$, $Vx9$ et $maxO3v$. On retrouve le résultat de la question 4.

1.8 Question 8

Le modèle avec le plus faible BIC est donc celui composé des variables citées ci-dessus, on obtient alors :

```
Call:
lm(formula = maxO3 ~ T12 + Ne9 + Vx9 + maxO3v, data = Ozone)

Residuals:
    Min       1Q   Median       3Q      Max
-52.396  -8.377  -1.086   7.951  40.933

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 12.63131    11.00088   1.148 0.253443
T12          2.76409     0.47450   5.825 6.07e-08 ***
Ne9         -2.51540     0.67585  -3.722 0.000317 ***
Vx9          1.29286     0.60218   2.147 0.034055 *
maxO3v       0.35483     0.05789   6.130 1.50e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 14 on 107 degrees of freedom
Multiple R-squared:  0.7622,    Adjusted R-squared:  0.7533
F-statistic: 85.75 on 4 and 107 DF,  p-value: < 2.2e-16
```

On remarque alors que 76% de la variable *maxO3* est expliqué par ses covariables (multiple R-squared) et que la valeur du R-squared ajusté est également très élevé (0.7533). De plus, si on compare au modèle de base, on obtient ceci :

```
Analysis of Variance Table


Model 1: maxO3 ~ T12 + Ne9 + Vx9 + maxO3v
Model 2: maxO3 ~ T9 + T12 + T15 + Ne9 + Ne12 + Ne15 + Vx9 + Vx12 + Vx15 +
maxO3v + vent + pluie
   Res.Df  RSS Df Sum of Sq    F Pr(>F)
1     107 20970
2      97 20410 10     560.09 0.2662 0.987
```

Ainsi, comme $P_r(> F) = 0.987$ cela signifie que ce nouveau modèle est un meilleur modèle que celui initialement proposé (avec l'ensemble des covariables).

1.9 Question 9





Pour valider le modèle choisi, on trace les graphiques suivants :

Validation en regression linéaire multiple



On remarque que la relation ajustés/observés est bien linéaire et que le graphique quantile-quantile forme bien une bijectice. Enfin, les résidus bruts sont faibles et les résidus studentisés ne montrent pas de dépendance ou de tendance et sont raisonnablement compris entre -2 et 2.

$\text{lm}(\text{maxO3} \sim \text{T12} + \text{Ne9} + \text{Vx9} + \text{maxO3v})$



On remarque qu'il n'existe pas de point dans les cadrans en haut à droite et en bas à droite du graphique 'Residuals vs Leverage'. Ainsi, il n'existe pas de point ayant un fort résidu, un fort levier et une grande distance de Cook. Ainsi, il n'y a pas de problématique de points influents.

1.10 Question 10

Pour calculer l'erreur de prédiction du modèle choisi, on utilise la méthode de validation croisée (codée dans le code R).

On obtient alors, par exemple dans le cas 'Leave-one-out', une erreur de prédiction du modèle choisi de $EQMP = 206.6881588$.

2 Exercice 2

2.1 Question 1

X peut-être singulière si :

1. Les colonnes de X ne sont pas indépendantes
2. $\text{rg}(X) < \min(n, p)$
3. X n'est pas injective
4. Le noyau de X n'est pas réduit au vecteur nul

2.2 Question 2

On considère la fonction de coût $J(\beta) : J(\beta) = (X\beta - y)^T(X\beta - y) + \lambda\beta^T\beta$

En dérivant, on obtient :

$$\nabla_{\beta} J = 2(X^T X + \lambda I)\beta - 2X^T y$$

$$\text{Finalement : } \nabla_{\beta} J(\beta^*) = 0 \iff \beta^* = (X^T X + \lambda I)^{-1} X^T y$$

2.3 Question 3

Supposons β_* solution du problème 2. Puisque $\beta^* \in \mathcal{R}^p, \|\beta^*\| \leq M_{\lambda}$ on a :

$$\|Y - X\beta_*\|^2 + \lambda\|\beta_*\|^2 \leq \|Y - X\beta^*\|^2 + \lambda\|\beta_*\|^2$$

$$\|Y - X\beta_*\|^2 + \lambda\|\beta_*\|^2 \leq \|Y - X\beta^*\|^2 + \lambda M_{\lambda}^2$$

$$\|Y - X\beta_*\|^2 + \lambda\|\beta_*\|^2 \leq \|Y - X\beta^*\|^2 + \lambda\|\beta^*\|^2$$

Par unicité de la solution au problème de minimisation 1, $\beta_* = \beta^*$

2.4 Question 4.a

On rappelle $\hat{\beta} = (X^T X + \lambda I)^{-1} X^T Y$. Seul Y est aléatoire dans cette expression. En passant à l'espérance, on obtient : $\mathbf{E}(\hat{\beta}) = (X^T X + \lambda I)^{-1} X^T \mathbf{E}(Y)$

Puisque ϵ est centrée, on a :

$$\mathbf{E}(\hat{\beta}) = (X^T X + \lambda I)^{-1} X^T X \beta$$

$$\text{D'où : } \text{Bias}(\hat{\beta}) = -\lambda(X^T X + \lambda I)^{-1} \beta$$

Si λ vaut 0, on retombe sur le résultat classique de l'estimateur des moindres carrés sans biais. Quand λ augmente, le biais diminue jusqu'à atteindre $-\beta$.

2.5 Question 4.b

De même que pour la question précédente et en utilisant les propriétés de la covariance :

$$\text{Var}(\hat{\beta}) = (X^T X + \lambda I)^{-1} X^T \text{Var}(Y) (X^T X + \lambda I)^{-1} X^T$$

$$\text{Var}(\hat{\beta}) = \sigma^2 (X^T X + \lambda I)^{-1} X^T X (X^T X + \lambda I)^{-1}$$

Si λ vaut 0, on retombe sur le résultat classique de l'estimateur des moindres carrés. Quand λ augmente, la variance diminue jusqu'à atteindre 0.

2.6 Question 5

Le fait de considérer le problème 1 permet de réduire la variance des coefficients obtenus. La régression Ridge est utilisée lorsque les variables considérées sont très corrélées. On obtient alors une solution qui constitue un compromis entre le problème d'optimisation linéaire et la minimisation de la variance des coefficients obtenus.