

Statistiques avancées

2A Cours électif CentraleSupélec

Sarah Lemler

2024



CentraleSupélec

TP2 : Modèle linéaire

1.2 Analyse uni- et bi-varié :

$$\text{Cor}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$$

1.2 Analyse uni- et bi-varié :

$$\text{Cor}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$$

1.3 Modéliser :

$$\begin{aligned} lpsa_i = & \beta_0 + \beta_1 \times lcavol_i + \beta_2 \times lweight_i + \beta_3 \times age_i + \beta_4 \times lbph_i + \beta_5 \times svi_i \\ & + \beta_6 \times lcp_i + \beta_7 \times gleason_i + \beta_8 \times pgg45_i + \varepsilon_i \end{aligned}$$

avec

- $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)^T$ un vecteur gaussien centré et de variance $\sigma^2 I_n$,
- le paramètre $\beta = (\beta_0, \beta_1, \beta_2, \beta_3, \beta_4, \beta_5, \beta_6, \beta_7, \beta_8)^T$ est de dimension 9,
- le modèle est identifiable,
- ici, $n=97$, $p=9$

1.4 Calcul à la main :

1.

$$\hat{\beta} = (X^T X)^{-1} X^T Y \quad \text{et} \quad \hat{\sigma}^2 = \frac{\|Y - X\hat{\beta}\|^2}{n-p} = \frac{\sum_{i=1}^n (Y_i - (X\hat{\beta})_i)^2}{n-p}$$

Attention ici, $p = \text{length}(\beta)$ tient déjà compte de l'intercept.

Fonction solve sur R :

- `solve(a,b)` permet de résoudre $ax = b$
- `solve(t(X)%*%X) = (X^T X)^{-1}`, inverse la matrice (en fait si on ne précise pas b , $b = Id$)

1.4 Calcul à la main :

1.

$$\hat{\beta} = (X^T X)^{-1} X^T Y \quad \text{et} \quad \hat{\sigma}^2 = \frac{\|Y - X\hat{\beta}\|^2}{n-p} = \frac{\sum_{i=1}^n (Y_i - (X\hat{\beta})_i)^2}{n-p}$$

Attention ici, $p = \text{length}(\beta)$ tient déjà compte de l'intercept.

Fonction solve sur R :

- `solve(a,b)` permet de résoudre $ax = b$
- `solve(t(X)%*%X) = (X^T X)^{-1}`, inverse la matrice (en fait si on ne précise pas b , $b = Id$)

2. Pour tout $j = 1, \dots, p$, $(H_0) \beta_j = 0$ contre $(H_1) \beta_j \neq 0$. Sous forme vectorielle, la statistique de test s'écrit :

$$T = \frac{\hat{\beta}}{\hat{\sigma} \sqrt{(X^T X)^{-1}}} \sim \mathcal{T}(n-p)$$

1.4 Calcul à la main :

1.

$$\hat{\beta} = (X^T X)^{-1} X^T Y \quad \text{et} \quad \hat{\sigma}^2 = \frac{\|Y - X\hat{\beta}\|^2}{n-p} = \frac{\sum_{i=1}^n (Y_i - (X\hat{\beta})_i)^2}{n-p}$$

Attention ici, $p = \text{length}(\beta)$ tient déjà compte de l'intercept.

Fonction solve sur R :

- `solve(a,b)` permet de résoudre $ax = b$
- `solve(t(X)%*%X) = (X^T X)^{-1}`, inverse la matrice (en fait si on ne précise pas b , $b = Id$)

2. Pour tout $j = 1, \dots, p$, $(H_0) \beta_j = 0$ contre $(H_1) \beta_j \neq 0$. Sous forme vectorielle, la statistique de test s'écrit :

$$T = \frac{\hat{\beta}}{\hat{\sigma} \sqrt{(X^T X)^{-1}}} \sim \mathcal{T}(n-p)$$

3. Par symétrie de la loi de Student,

$$\begin{aligned} p\text{-value} &= \mathbb{P}(|\mathcal{T}(n-p)| > |t_{obs}|) = \mathbb{P}(\mathcal{T}(n-p) > |t_{obs}| \text{ ou } \mathcal{T}(n-p) < -|t_{obs}|) \\ &= 2\mathbb{P}(\mathcal{T}(n-p) < -|t_{obs}|) \\ &= 2\mathbb{P}(\mathcal{T}(n-p) > |t_{obs}|) \end{aligned}$$

1.6 Intervalle de confiance :

1. IC de niveau 95% ($\alpha = 0.05$) de β :

$$IC_{1-\alpha}(\beta) = \left[\hat{\beta} - t_{n-p}(1 - \alpha/2) \hat{\sigma} \sqrt{(X^T X)^{-1}}, \hat{\beta} + t_{n-p}(1 - \alpha/2) \hat{\sigma} \sqrt{(X^T X)^{-1}} \right]$$

1.6 Intervalle de confiance :

1. IC de niveau 95% ($\alpha = 0.05$) de β :

$$IC_{1-\alpha}(\beta) = \left[\hat{\beta} - t_{n-p}(1 - \alpha/2) \hat{\sigma} \sqrt{(X^T X)^{-1}}, \hat{\beta} + t_{n-p}(1 - \alpha/2) \hat{\sigma} \sqrt{(X^T X)^{-1}} \right]$$

2. IC de niveau 95% du lpsa moyen :

- $x_{new} = (1, 0.75, 3.43, 62, -1.39, 0, -1.39, 6, 0)$
- $L = x_{new}$ matrice de dimension 1×9
- Intervalle de confiance de niveau $1 - \alpha$ d'une forme linéaire :

$$IC_{1-\alpha}(L\beta) = IC_{1-\alpha}(x_{new}\beta)$$

$$IC_{1-\alpha}(x_{new}\beta) = \left[x_{new}\hat{\beta} \pm t_{n-p}(1 - \alpha/2) \hat{\sigma} \sqrt{x_{new}(X^T X)^{-1}x_{new}^T} \right]$$

1.6 Intervalle de confiance :

1. IC de niveau 95% ($\alpha = 0.05$) de β :

$$IC_{1-\alpha}(\beta) = \left[\hat{\beta} - t_{n-p}(1 - \alpha/2) \hat{\sigma} \sqrt{(X^T X)^{-1}}, \hat{\beta} + t_{n-p}(1 - \alpha/2) \hat{\sigma} \sqrt{(X^T X)^{-1}} \right]$$

2. IC de niveau 95% du lpsa moyen :

- $x_{new} = (1, 0.75, 3.43, 62, -1.39, 0, -1.39, 6, 0)$
- $L = x_{new}$ matrice de dimension 1×9
- Intervalle de confiance de niveau $1 - \alpha$ d'une forme linéaire :

$$IC_{1-\alpha}(L\beta) = IC_{1-\alpha}(x_{new}\beta)$$

$$IC_{1-\alpha}(x_{new}\beta) = \left[x_{new}\hat{\beta} \pm t_{n-p}(1 - \alpha/2) \hat{\sigma} \sqrt{x_{new}(X^T X)^{-1}x_{new}^T} \right]$$

3. Intervalle de prévision de niveau 95% pour une valeur individuelle du lpsa :

$$IP_{1-\alpha}(Y_{new}) = \left[x_{new}\hat{\beta} \pm t_{n-p}(1 - \alpha/2) \hat{\sigma} \sqrt{x_{new}(X^T X)^{-1}x_{new}^T + 1} \right]$$

1.7 Tester et sélectionner des variables

- $SCRH1 = \|Y - X\hat{\beta}\|^2$ (modèle complet) et
 $SCRH0 = \|Y - \hat{\beta}_0 \mathbf{1}\|^2 = \|Y - \mathbb{E}(Y)\|^2$ (modèle iid : $Y = \beta_0 \mathbf{1} + \varepsilon$)
- $F = \frac{(SCRH0 - SCRH1)/(p - q)}{SCRH1/(n - p)} = 20.86$
- quantile de la loi $\mathcal{F}_{p-q, n-p}(1 - \alpha)$: $f_{p-q, n-p}(1 - \alpha) = 2.04$
- $\mathcal{R}_\alpha = \{F > f_{p-q, n-p}(1 - \alpha)\}$
- $p\text{-value} = \mathbb{P}(\mathcal{F}_{p-q, n-p} > f_{obs})$

$\Rightarrow$ ici on rejette (H_0)

2.3 Modéliser :

Modèle ANCOVA sous sa forme singulière :

$$Y_{ik} = (\mu + a_k) + (\beta + b_k) \times invdebit_i + \varepsilon_{ik}, \quad i = 1, \dots, n_k \text{ et } k = 1, \dots, 4$$

- Y_{ik} délai pour l'expérience i avec le système k , ici $n_k = 24$ (car pour chaque système, on a 24 mesures de délais : 8 débits différents et 3 mesures par système et par débit)
- μ effet général et a_k pour $k = 1, \dots, 4$ effet principal lié au système
- β effet général de la covariable *invdebit* et b_k pour $k = 1, \dots, 4$ effet principal de la covariable lié au système

On va avoir besoin de 2 contraintes

Modèle ANCOVA sous forme singulière dans R :

```
lm(delai~systeme*invdebit,data=perf)
```

2.4 Estimer :

1. Par défaut, **R** choisit comme contrainte d'annuler le premier effet principal, c'est-à-dire l'effet lié au système 1 : $\hat{a}_1 = 0$ et $\hat{b}_1 = 0$

Dans ce cas, on a pour $k = 2, 3, 4$:

- $\hat{\mu}_1 = \widehat{\mu + a_1} = \hat{\mu}$
- $\hat{\mu}_k = \widehat{\mu + a_k}$ donc $\hat{a}_k = \hat{\mu}_k - \hat{\mu}$
- $\hat{\beta}_1 = \widehat{\beta + b_1} = \hat{\beta}$
- $\hat{\beta}_k = \widehat{\beta + b_k}$ donc $\hat{b}_k = \hat{\beta}_k - \hat{\beta}$

Remarque : Les estimations obtenues dans **R** correspondent aux estimations de μ , a_k , β et b_k pour $k = 1, \dots, 4$ respectivement

- $\hat{\mu}$ représente la valeur de la réponse pour le niveau 1
- $\hat{a}_k = \hat{\mu}_k - \hat{\mu}$ représente la différence de réponse entre le niveau k et le niveau pris comme référence (ici S1)

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-33.53225	7.88743	-4.251	5.27e-05	***
systemeS2	37.17563	11.15451	3.333	0.001259	**
systemeS3	40.41060	11.15451	3.623	0.000487	***
systemeS4	-0.08376	11.15451	-0.008	0.994026	
perf\$invdebit	5040.73955	45.28203	111.319	< 2e-16	***
systemeS2:perf\$invdebit	1885.29121	64.03846	29.440	< 2e-16	***
systemeS3:perf\$invdebit	3498.17622	64.03846	54.626	< 2e-16	***
systemeS4:perf\$invdebit	-35.51081	64.03846	-0.555	0.580627	

Sur la 1^{ère} colonne de haut en bas, on a $\hat{\mu}$, $\hat{a}_2$, $\hat{a}_3$, $\hat{a}_4$, $\hat{\beta}$, $\hat{b}_2$, $\hat{b}_3$ et $\hat{b}_4$.

3. Modèle $\text{lm}(\text{delai} \sim \text{system} + \text{system}:\text{invdebit}, \text{data}=\text{perf})$:

$$Y_{ik} = (\mu + a_k) + b_k \times \text{invdebit}_i + \varepsilon_{ik}, \quad k = 1, \dots, 4, i = 1, \dots, n_k$$

⇒ pas d'effet général pour la covariable *invdebit*

⇒ besoin d'une seule contrainte

Contrainte choisie par **R** : $\hat{a}_1 = 0$

2.7 Intervalle de confiance :

On veut un intervalle de confiance de $Y_2 - Y_3$, où

$$Y_2 = \mu + a + (\beta + b_2) \times \text{invdebit} + \varepsilon_2$$

$$Y_3 = \mu + a + (\beta + b_3) \times \text{invdebit} + \varepsilon_3$$

pour $\text{invdebit} = 1/5 = 0.2$. On en déduit que

$$\hat{Y}_3 - \hat{Y}_2 = (\hat{b}_3 - \hat{b}_2) \times \text{invdebit}$$

On pose $L = (-1 \quad 1) \times 0.2$ et $b = (b_2 \quad b_3)^T$, on a

$$\frac{L\hat{b} - Lb}{\hat{\sigma} \sqrt{L[(X^T X)^{-1}]L^T}} \sim \mathcal{T}_{n-p}$$

où $\hat{\sigma} \sqrt{L[(X^T X)^{-1}]L^T} = \text{vcov}(M5)[4:5, 4:5]$

$$Lb \in \left[L\hat{b} \pm qt(1 - \alpha, n - p) \hat{\sigma} \sqrt{L[(X^T X)^{-1}]_{4,5} L^T} \right]$$

avec $p = 5$