
Rapport final du projet

Analyse de la supply chain afin d'améliorer la promesse client

Pôle projet : P18 Production, Supply Chain et Opérations

Membres du groupe

Corentin VENET

Martin RIO

Achraf MANSOURI

Adam BEN ATTIA

Mathilde JOUBERT DE LA MOTTE

Tuteurs entreprise

Nicolas SCHNELL

Nabil BENMANSOUR

Tuteur école

Quentin TUILIER



LOUIS VUITTON

Table of contents

1	Présentation du projet	2
1.1	Présentation de l'entreprise	2
1.2	Contexte du project	2
1.3	Problématique, objectifs et livrables	2
1.4	Notre organisation au sein du groupe	2
2	La Supply Chain chez Louis Vuitton	4
2.1	Cartographie globale	4
2.2	Méthode DDMRP	5
2.3	Backorders	5
3	Analyse de données	7
3.1	Données à disposition	7
3.2	Nettoyage des données	7
4	Calcul des variations des paramètres	9
4.1	Variation de la visibilité cumulée	9
4.1.1	Données nécessaires	9
4.1.2	Détails du calcul	9
4.2	Variation du PDL	10
4.2.1	Données nécessaires	10
4.2.2	Détails du calcul	11
4.3	Variation du Forecast	12
4.3.1	Données nécessaires	12
4.3.2	Détails du calcul	12
4.4	Variation du besoin de distribution	12
4.4.1	Données nécessaires	12
4.4.2	Détails du calcul	13
5	Deux méthodes de détermination des causes de non-respect des délais	15
5.1	Méthode statistique	15
5.1.1	Arbre de décision	15
5.1.2	Détermination des seuils	16
5.1.3	Impact de l'ordre de considération	17
5.2	Méthode de clustering	17
5.2.1	Choix de la méthode Density-Based Spatial Culstering of Applications with Noise	18
5.2.2	Fonctionnement et implémentation de la méthode DBSCAN	18
6	Résultats	20
6.1	Résultats obtenus avec la méthode statistique	20
6.2	Résultats obtenus avec la méthode des clusters	21
7	Conclusion	23
7.1	Interprétation des résultats	23
7.2	Perspectives	23
8	Remerciements	24
9	Annexe – mode d'emploi	25

Chapitre 1

Présentation du projet

1.1 Présentation de l'entreprise

Louis Vuitton est une maison de couture de luxe fondée en 1854. Depuis lors, elle promet l'excellence à ses clients afin de préserver son histoire légendaire. Pour offrir une qualité exceptionnelle, la direction de la chaîne d'approvisionnement de Louis Vuitton se consacre à la production et à la livraison des produits aux clients du monde entier à partir de ses ateliers. Afin de préserver l'image de la marque de luxe et l'excellence de son travail, l'équipe de la chaîne d'approvisionnement se concentre sur les promesses faites aux clients pour les satisfaire.

1.2 Contexte du projet

Dans la chaîne d'approvisionnement de Louis Vuitton, l'intégration s'étend de la production des produits dans les ateliers à leur vente dans les magasins, ce qui permet d'utiliser les données à tous les niveaux de la chaîne d'approvisionnement. Cette intégration stratégique permet à Louis Vuitton de développer des stratégies innovantes qui améliorent les promesses faites aux clients et, par conséquent, façonnent son image de marque dans le secteur du luxe.

Ce projet se concentre spécifiquement sur l'optimisation d'une partie importante, 20%, des ventes de LV ou des transactions effectuées sans stocks disponibles. Les clients passent ces commandes par l'intermédiaire des canaux de commerce électronique ou en soumettant des demandes en magasin. LV s'engage alors à respecter un délai précis pour la livraison du produit demandé. Pour préserver son image de marque et garantir la satisfaction de ses clients, LV accorde une grande importance à l'exactitude de ces délais, en veillant à ce que les produits parviennent aux clients à la date prévue.

Malgré l'attention méticuleuse portée aux délais, des retards occasionnels dans l'exécution des commandes sont constatés parmi les millions de transactions traitées. Pour résoudre ce problème et améliorer de manière proactive la satisfaction des clients, LV cherche à identifier les causes profondes des retards dans les commandes. En comprenant ces facteurs, l'objectif est de formuler des solutions efficaces qui permettront à LV d'affiner ses promesses aux clients et, par la suite, d'augmenter la satisfaction globale des clients.

1.3 Problématique, objectifs et livrables

Comment les erreurs de planification dans la supply chain de Louis Vuitton affectent-elles la fiabilité du délai de livraison donné aux clients ?

Nos objectifs, pour améliorer la promesse client, seront les suivants :

- Comprendre l'organisation de la supply chain chez Louis Vuitton ;
- Décrire la superposition des effets de planification ;
- Identifier les causes des délais de livraison incorrects.

Nos livrables seront :

- Le code Python détaillé de l'algorithme permettant de déterminer les causes des changements de délai ;
- Une analyse statistique des causes des délais de livraison incorrects.

1.4 Notre organisation au sein du groupe

Dans notre projet, l'organisation et la planification des actions ont été des éléments cruciaux qui ont contribué de manière significative à notre succès. Corentin a joué un rôle clé au sein du projet, en tant que seule personne

repreuant le projet en S8, il a été le coordinateur de l'équipe et a permis de faire le lien avec l'équipe encadrante. Mathilde, notre facilitatrice, a assuré une communication fluide entre les membres de l'équipe, a assigné des tâches individuelles pour le travail de projet et s'est assurée de l'avancement régulier de chacun. Adam, notre expert technique, a apporté un soutien crucial dans le développement et la mise en œuvre des solutions techniques du projet. Il a identifié les outils et technologies nécessaires et assuré leur intégration. Martin a joué le rôle de planificateur stratégique et a été essentiel dans la définition des objectifs et des jalons du projet. Il a élaboré un calendrier détaillé et veillé à ce que toutes les étapes soient respectées. Achraf, notre motivateur, a dynamisé l'équipe en maintenant un haut niveau de moral et d'engagement ; dans les moments de difficulté, il a su être présent pour nous permettre collectivement d'avancer...

Notre structure organisationnelle s'appuyait fortement sur WhatsApp et sur des réunions d'équipe en fonction des besoins. Nous avons organisé des réunions régulières avec nos superviseurs, les tuteurs de LV et CentraleSupélec, et ces réunions ont été cruciales pour progresser. Nous avons utilisé des outils tels que des diagrammes de Gantt, des notes de réunion et des enregistrements, qui se sont révélés très utiles. La communication s'est faite principalement par WhatsApp, et la répartition des tâches a été gérée par la même plateforme. Dans l'ensemble, cette approche collaborative et bien organisée a été déterminante pour le bon fonctionnement et l'avancement de notre projet.

Chapitre 2

La Supply Chain chez Louis Vuitton

2.1 Cartographie globale

Dans sa forme la plus simple, la chaîne d’approvisionnement de Louis Vuitton comprend des ateliers de production, des centres de distribution centraux (CDC) et des centres de distribution régionaux (RDC) où les produits sont stockés et préparés pour la distribution. Le point final de la chaîne est le magasin de détail, qui sert à la fois d’entrepôt pour les produits et d’interface cruciale entre les clients et la marque. Pour analyser en détail les différentes étapes de la livraison des produits Louis Vuitton et déterminer les raisons des imprécisions en termes de délais, nous nous sommes concentrés sur une référence SKU spécifique, M46203. Ce sac étant vendu en collection permanente, nous avons accès à une quantité importante de données sur plusieurs mois.



FIGURE 2.1 – produit SKU M46203

À partir de différentes données extraites, nous avons retracé les différents chemins d’approvisionnement possibles du produit M46203, et ceci depuis les ateliers de fabrication jusqu’aux magasins de vente regroupés par zones géographiques (en passant donc par les CDC puis les RDC). Cette cartographie du produit sera par la suite essentielle afin de déterminer les origines des retards dans les délais de commande.




FIGURE 2.2 – Cartographie de la supply chain pour le produit M46203

2.2 Méthode DDMRP

Cependant, bien que la structure de la chaîne d'approvisionnement semble ne comporter que quelques couches, la mise en œuvre de la méthodologie DDMRP (Demand Driven Material Requirements Planning) introduit des complexités supplémentaires. Cette méthodologie permet d'intégrer l'ensemble du système et de réagir rapidement aux variations de la demande.

La méthodologie DDMRP est employée dans la gestion de la chaîne d'approvisionnement des produits LV pour améliorer la réactivité aux changements de la demande, en s'écartant des méthodes traditionnelles qui s'appuient uniquement sur des prévisions, ce qui peut entraîner des résultats de planification imprécis. Pour améliorer la capacité d'adaptation aux fluctuations de la demande, des stocks tampons ont été stratégiquement positionnés le long de la chaîne d'approvisionnement. Ces stocks tampons comprennent trois niveaux distincts : vert, jaune et rouge. Chaque zone se voit attribuer un nombre spécifique de stocks, calculé à l'aide de formules prédéfinies.




FIGURE 2.3 – Schéma des stocks par la méthode DDMRP

[zone verte : ADU (Average Daily Units) x nombre de réapprovisionnement]

[zone jaune : ADU x délai de livraison]

[zone rouge : ADU x variabilité]

Les zones verte et jaune sont désignées pour faciliter la circulation des produits, tandis que la zone rouge sert de mesure de sécurité, en tenant compte de la variabilité des ventes. Cette précaution garantit qu'en cas de changement soudain de la demande, la chaîne d'approvisionnement peut encore répondre efficacement aux besoins des clients. Pour chaque produit, ces stocks tampons sont méticuleusement répartis à chaque étape, notamment dans les magasins, les centres de distribution régionaux (RDC) et les centres de distribution centraux (CDC), ce qui permet un suivi complet des niveaux de stocks tout au long de la chaîne d'approvisionnement. Des mises à jour régulières sont effectuées en fonction des informations sur la demande actuelle afin d'optimiser la gestion des stocks et d'améliorer la réactivité globale.

2.3 Backorders

En tant qu'entreprise de luxe, Louis Vuitton s'abstient de proposer des soldes, ce qui nécessite une production précise des commandes afin d'éviter d'accumuler des stocks inutilisés. Par conséquent, l'entreprise évite la production de masse, ce qui entraîne l'apparition de "backorders". Les "backorders" surviennent lorsqu'un client passe une commande pour un produit qui n'est pas en stock, soit par l'intermédiaire des canaux de commerce électronique en ligne, soit en faisant une demande dans les magasins. Lorsqu'une telle commande est passée, Louis Vuitton fournit au client une date d'arrivée prévue du produit, lui permettant d'anticiper la date à laquelle il recevra le produit demandé. Cette date est déterminée à l'aide du délai d'approvisionnement (lead time) et du concept de visibilité, tous deux issus de la méthodologie DDMRP employée par Louis Vuitton. Le délai de livraison (LT) représente le nombre de jours entre la réception de la commande et la livraison. Il est calculé pour chaque combinaison SKU x Magasin et mis à jour quotidiennement. Par exemple, l'arrivée d'un produit peut être estimée entre 2 et 3 semaines. Ce délai est déterminé à partir de la visibilité, qui peut être exprimée par la formule suivante :

$$\text{Visibilité} = \text{Stock (ce que le magasin possède)} + \text{PDL (ce que le magasin est supposé recevoir)} - \text{Forecast (ce que le magasin s'attend à vendre)}$$

Comme le montre la formule ci-dessus, le calcul de la visibilité implique différentes étapes de la supply chain, depuis la planification de la production avec les données PDL (Plan De Livraison), jusqu'au contrôle des niveaux de stock dans les centres de distribution (CDC et RDC) et, enfin, dans la gestion de la supply chain grâce à l'utilisation des prévisions (Forecast). Étant donné que la méthode DDMRP employée par Louis Vuitton rend la chaîne d'approvisionnement très réactive, les valeurs de visibilité peuvent être modifiées en permanence.

Le calcul de la visibilité cumulée occupe une place centrale dans notre étude, car il est intrinsèquement lié au délai de livraison (Lead Time) de la manière suivante :




FIGURE 2.4 – Lien entre délai de livraison (LT) et visibilité cumulée

Ce graphique illustre le lien entre la visibilité cumulée et le délai de livraison des produits. Globalement, la visibilité cumulée représente le nombre de commandes pouvant être satisfaites en fonction du temps. Pour un certain nombre de commandes en attente (c'est-à-dire des commandes qui ne correspondent pas à une livraison immédiate au client) la visibilité calculée permet donc d'obtenir un Lead Time basé sur la logique du FIFO (First In First Out : les premiers clients livrés sont ceux qui ont commandé en premier). Ainsi, plus la visibilité cumulée est grande, plus le LT est faible et les commandes livrées rapidement. Il est à noter que Louis Vuitton impose une limite temporelle au LT communiqué aux clients, faute de quoi un client pourrait attendre des années avant de recevoir son article. Il en résulte donc un nombre limite de commandes en attente acceptées, appelé quota.

La complexité du calcul de la visibilité peut conduire à des imprécisions dans la fourniture d'informations sur les délais au client, ce que Louis Vuitton cherche à éviter en raison de son engagement dans l'amélioration constante des promesses faites au client. Par conséquent, l'objectif du projet est de comprendre cette complexité et d'étudier les raisons de l'inexactitude des délais en analysant les données relatives à la supply chain.

Chapitre 3

Analyse de données

3.1 Données à disposition

L'étude des imprécisions dans les délais de commande s'est appuyée sur un examen approfondi des commandes du produit SKU M46203 présenté précédemment. Pour notre étude, Louis Vuitton nous a fourni deux types de fichiers Excel. Le premier recense chaque commande et les informations correspondantes telles que l'état de livraison de l'article, les dates de livraison estimées et réelles, ainsi que les ateliers de production. Le second fichier Excel, beaucoup plus volumineux, correspond aux archives des différents paramètres calculés par les serveurs de LV. Ces paramètres sont au nombre de 4 :

- **Visibilité** au niveau des centres de distribution régionaux (voir formule et interprétation ci-dessus) ;
- **Plan De Livraison (PDL)** : nombre de commandes produites au niveau de chaque atelier ;
- **Besoin de distribution (BD)** : nombre de commandes nécessaires aux centres de distribution centraux (CDC) afin de satisfaire les commandes en attente et les commandes prédites ;
- **Forecast** : prédiction du nombre de commandes vendues par zone géographique.

Il est important de noter immédiatement que ces quatre paramètres sont loin d'être indépendants. Bien au contraire, le changement de l'un d'entre eux peut engendrer des modifications en cascade des autres paramètres. Cette complexité représentera un premier challenge significatif dans l'établissement de l'origine d'un manquement au respect des délais de livraison.

L'objectif du projet est donc d'analyser ces données et notamment les variations temporelles des différents paramètres afin de conclure sur l'impact de chaque paramètre sur le respect des délais de livraison.

3.2 Nettoyage des données

Avant de nous lancer dans l'analyse de ces données, nous avons pris le temps de décrypter la signification de chaque feuille de calcul, afin d'en déduire une certaine logique dans l'enchaînement des étapes. Nous nous sommes alors rendu compte que les données fournies ne permettaient pas un suivi complet de toutes les commandes, depuis la sortie de l'atelier jusqu'à l'arrivée en magasin (par exemple en raison d'informations manquantes sur le RDC ou le magasin). Par conséquent, nous avons procédé à un nettoyage des données afin de ne conserver que celles qui pouvaient être traitées.

Ce tri des commandes a été facilité par un programme Python, repris en annexe. La plupart des données que nous n'allons pas utiliser le sont en raison d'un manque d'information concernant l'état de livraison de la commande. Effectivement, sans accès à cette information, il est impossible de tirer de conclusion sur une éventuelle imprécision de détail pour une telle commande.

De plus, certaines données sont également mises de côté car les RDC et les magasins correspondant à ces commandes ne sont pas ceux pour lesquels les différents paramètres sont calculés. Ainsi, dans ce cas de figure, il serait impossible de déterminer une éventuelle origine au non-respect d'un délai.

Concernant les commandes restantes, nous devons pour la suite de notre analyse les comparer aux archives. Cependant, ces archives sont effacées régulièrement. Ainsi, dans notre cas, seules 403 commandes sont utilisables pour la suite du projet. En revanche, une extraction fréquente des données permettrait une analyse plus large et éviterait la dernière étape de réduction des données. Si l'extraction se fait tous les mois, nous pourrions fonder notre analyse sur l'année entière.

Le nettoyage des données est résumé dans le graphique suivant :




FIGURE 3.1 – Graphique d'explication du nettoyage des données

Chapitre 4

Calcul des variations des paramètres

Comme exposé précédemment, l'analyse des origines du non-respect des délais de livraison se base sur une étude de la variation des 4 paramètres recensés.

Nous allons ainsi détailler ici le calcul de variation de ces paramètres. Pour cela, nous allons nous baser sur un exemple concret. Prenons le cas réel d'une commande extraite des informations fournies par Louis Vuitton. Voici les détails de cette commande, récupérables dans le premier fichier Excel (qui recense les informations des différentes commandes) :

date de commande : 10/12

période d'arrivée donnée au client : 15/12 - 19/12

date de livraison réelle : 27/12

magasin de livraison : L36

Tout d'abord, grâce au code du magasin de livraison, nous sommes en mesure de connaître les lieux de provenance de cette commande : région (Asie du Sud), RDC (N71) et CDC (FRA). Ces informations sont cruciales pour déterminer les variations des paramètres relatifs à cette commande.

4.1 Variation de la visibilité cumulée

4.1.1 Données nécessaires

Concernant la visibilité cumulée, l'objectif est de calculer la différence au jour réel de livraison entre la visibilité cumulée prédite au jour de commande et la visibilité réelle au jour de livraison.

Pour cela, il est nécessaire de recueillir certaines données du fichier Excel d'archives : les données de prédiction de visibilité au jour de commande (10/12) et les données de visibilité au jour de livraison réel (27/12) au niveau du RDC N71. Ces données sont présentées dans le tableau suivant en rouge.

			Semaine concernée par les prédictions		
			W50	W51	W52
Jour de prédiction	Jour de commande 10/12	Visibilité	917	534	95
		Visibilité cumulée	917	1451	1546
	Jour de livraison réel 27/12	Visibilité			174
		Visibilité cumulée			1091

FIGURE 4.1 – Données extraites des archives pour le calcul de la variation de visibilité cumulée

4.1.2 Détails du calcul

Visibilité cumulée prédite

Pour obtenir la visibilité cumulée prédite, c'est-à-dire celle de la première ligne du tableau ci-dessus, il suffit de calculer une somme progressive des valeurs de visibilité.

Les données de visibilité étant référencées par semaine, si on extrapole les tracés de visibilité cumulée comme étant des droites affines, alors on peut par proportionnalité obtenir une valeur de visibilité cumulée au jour réel de livraison : **1492**. Ce premier résultat est schématisé par la courbe bleue dans le graphique suivant.




FIGURE 4.2 – Graphique de visibilité cumulée en fonction du temps pour notre exemple de commande

Visibilité cumulée réelle

Afin d'obtenir la visibilité cumulée réelle au jour de livraison, il suffit de s'intéresser au nombre de commandes en attente le jour de la commande. En effet, dans notre exemple, le 10/12 il a été annoncé au client une livraison entre le 15/12 et le 19/12, disons donc le 17/12. Si on regarde alors le tracé de la visibilité cumulée prédite ce jour-ci (tracé bleu), cela signifie qu'il y avait déjà 917 "backorders". Ainsi, par respect du FIFO, cela signifie que cette 917ème commande a été livrée le 27/12 et donc que la visibilité cumulée réelle au 27/12 est de **917**.

On peut alors déterminer le point d'origine de la courbe orange du graphique ci-dessus comme étant cette valeur. Cela signifie qu'en réalité, le tracé réel de la visibilité cumulée a suivi la tracé en pointillés oranges plutôt que le tracé bleu, d'où le non-respect du délai de livraison annoncé au client !

Variation relative

Il ne reste donc plus qu'à calculer la variation entre ces deux valeurs de visibilité cumulée :

$$\text{Variation de la visibilité cumulée} = \frac{917 - 1492}{1492} = -38,5\%$$

On retrouve bien ici le fait qu'une diminution de la visibilité cumulée est liée à une augmentation du délai de livraison.

4.2 Variation du PDL

4.2.1 Données nécessaires

Concernant le Plan De Livraison, l'objectif est de calculer la variation entre les prévisions de production des ateliers au jour de commande et les valeurs de production réelles à la date de livraison.

Pour cela, il est nécessaire de récolter certaines données du fichier Excel d'archives. Si on s'intéresse aux valeurs de PDL entre le 10/12 et le 27/12, on obtient les données suivantes :

On remarque que les valeurs de PDL sont calculées quotidiennement. On a ici récupéré les valeurs correspondant à l'ensemble des ateliers produisant pour le centre de distribution correspondant à notre commande : CDC-FRA.

		Semaine concernée par les prédictions		
		W50	W51	W52
Jour de prédiction	10-déc	3438	3414	578
	11-déc	3160	3414	578
	12-déc	3462	2906	606
	13-déc	3372	2816	606
	14-déc	3372	2868	624
	15-déc	2694	2775	513
	16-déc	3372	3105	633
	17-déc	3372	3105	633
	18-déc		3051	633
	19-déc		3198	480
	20-déc		2878	450
	21-déc		2878	450
	22-déc		2878	450
	23-déc		2878	450
	24-déc		2878	450
	25-déc			394
	26-déc			401
	27-déc			342

FIGURE 4.3 – Données extraites des archives pour le calcul de la variation de PDL

Grâce à ce tableau récapitulatif, on peut alors mettre en évidence 2 types de données que nous allons comparer par la suite :

- En **rouge**, les valeurs de prédiction de PDL au jour de commande pour chaque semaine :
 - Semaine W50 : prévision initiale de 3438 unités ;
 - Semaine W51 : prévision initiale de 3414 unités ;
 - Semaine W52 : prévision initiale de 578 unités.
- En **vert**, les valeurs réelles de PDL (unités réellement produites par les ateliers à la fin de la semaine concernée) :
 - Semaine W50 : valeur réelle de 3372 unités ;
 - Semaine W51 : valeur réelle de 2878 unités ;
 - Semaine W52 : valeur réelle de 342 unités.

4.2.2 Détails du calcul

Variations par semaine

À partir de ces données, il est alors possible de calculer les variations entre les valeurs de prédiction et les valeurs réelles de PDL par semaine :

- Variation pour la semaine W50 :

$$\Delta W50 = \frac{3372 - 3438}{3438} = -0,019 = -1,9\%$$

- Variation pour la semaine W51 :

$$\Delta W51 = \frac{2878 - 3414}{3414} = -15,7\%$$

- Variation pour la semaine W52 :

$$\Delta W52 = \frac{342 - 578}{578} = -40\%$$

Variation globale

À ce stade, nous pouvons calculer la variation globale de PDL entre la date de commande et la date de livraison. On calcule alors la moyenne pondérée des variations de chaque semaine. Pour notre exemple, voici le résultat obtenu :

$$\text{Variation de PDL} = \frac{(-1,9\% \times 3372) + (-15,7\% \times 2878) + (-40\% \times 342)}{3372 + 2878 + 342} = -10,0\%$$

4.3 Variation du Forecast

4.3.1 Données nécessaires

Le calcul de variation du paramètre du forecast est presque similaire en tous points à celui du calcul de variation de PDL, à deux particularités près :

- Le forecast n'est calculé que toutes les semaines. Ainsi, lorsque l'on souhaite connaître la valeur du forecast à une certaine date, il est nécessaire de remonter jusqu'à la dernière valeur de forecast calculée, qui est donc la valeur prise en considération pour la détermination du délai de livraison.
- Le forecast est calculé pour une zone géographique (contrairement à un ensemble d'ateliers de production pour le PDL), il est nécessaire d'implémenter donc dans le raisonnement cette spécification. Dans notre exemple, la région correspondante à notre commande est l'Asie du Sud.

On obtient alors dans notre exemple les données suivantes :

		Semaine concernée par les prédictions		
		W50	W51	W52
Jour de prédiction	09-déc	148	301	299
	16-déc		301	299
	23-déc			424

FIGURE 4.4 – Données extraites des archives pour le calcul de la variation de forecast

De même, grâce à ce tableau récapitulatif, on peut alors mettre en évidence deux types de données que nous allons comparer par la suite :

- En **rouge**, les valeurs de prédiction de forecast au jour de commande pour chaque semaine :
 - Semaine W51 : prévision initiale de 301 unités ;
 - Semaine W52 : prévision initiale de 299 unités.
- En **vert**, les valeurs ajustées de forecast et considérées en réalité :
 - Semaine W51 : valeur réelle de 301 unités ;
 - Semaine W52 : valeur réelle de 424 unités.

4.3.2 Détails du calcul

Les calculs pour obtenir la variation finale de forecast entre la date de commande et la date de livraison sont alors identiques à ceux utilisés pour le PDL.

Variations par semaine

- Variation pour la semaine W51 :

$$\Delta W51 = \frac{301 - 301}{301} = 0\%$$

- Variation pour la semaine W52 :

$$\Delta W52 = \frac{424 - 299}{299} = +42\%$$

Variation globale

$$\text{Variation de Forecast} = \frac{(0\% \times 301) + (42\% \times 424)}{301 + 424} = +24,6\%$$

4.4 Variation du besoin de distribution

4.4.1 Données nécessaires

L'étude de la variation du besoin de distribution possède une caractéristique particulière. En effet, le besoin de distribution de la semaine actuelle prend en considération deux aspects :

- Le besoin de distribution intrinsèque à la semaine, c'est-à-dire le nombre d'unités nécessaires au CDC correspondant afin de respecter les délais de livraison des commandes prévues cette semaine-ci ;

- Le besoin de distribution nécessaire pour rattraper les commandes en retard depuis le lancement du produit.

Ainsi, au début de chaque semaine, le besoin de distribution "récupère" la partie correspondant aux commandes non livrées qui s'accumulent. Il nous est donc impossible de comparer les valeurs des archives de la même manière que précédemment. À partir du fichier Excel d'archives, on a alors la possibilité d'obtenir les données suivantes dans le cadre de notre exemple :

		Semaine concernée par les prédictions		
		W50	W51	W52
Jour de prédiction	10-déc	21272	3240	4278
	11-déc	21816	3210	4278
	12-déc	22067	3210	4278
	13-déc	22673	3211	4278
	14-déc	22657	3211	4278
	15-déc	22708	3211	4280
	17-déc		21198	4478
	18-déc		22292	4479
	19-déc		22512	4479
	20-déc		22620	4479
	21-déc		22285	4863
	22-déc		22264	4863
	23-déc		22802	5112
	24-déc			24106
	25-déc			24879
	26-déc			25063
	27-déc			24951

FIGURE 4.5 – Données extraites des archives pour le calcul de la variation du besoin de distribution

On peut alors mettre en évidence différents types de données :

- En **rouge**, les valeurs de prédiction du BD au jour de commande pour chaque semaine :
 - Semaine W50 : prévision initiale de 21272 unités ;
 - Semaine W51 : prévision initiale de 3240 unités ;
 - Semaine W52 : prévision initiale de 4278 unités.
- En **vert**, les valeurs du BD actualisées et considérées en réalité :
 - Semaine W50 : valeur réelle de 22708 unités ;
 - Semaine W51 : valeur réelle de 22802 unités ;
 - Semaine W52 : valeur réelle de 24951 unités.
- En **bleu**, les valeurs du BD actualisées **avant** la récupération du besoin de distribution des commandes en retard accumulées :
 - Semaine W51 : valeur actualisée de 3211 unités ;
 - Semaine W52 : valeur actualisée de 5112 unités.
- En **violet**, les valeurs du BD actualisées **après** la récupération du besoin de distribution des commandes en retard accumulées :
 - Semaine W51 : valeur actualisée de 21198 unités ;
 - Semaine W52 : valeur actualisée de 24106 unités.

4.4.2 Détails du calcul

Variations par semaine

Le calcul des variations par semaine pour ce paramètre diffère donc des autres, en raison de la récupération du besoin de distribution des commandes en retard accumulées. Ainsi, pour chaque semaine, la variation du besoin de distribution correspond à une somme des variations de BD avant cette récupération et après cette récupération, comme détaillé ci-dessous :

- Variation pour la semaine W50 :

$$\Delta W50 = \frac{22708 - 21272}{21272} = +6,8\%$$

- Variation pour la semaine W51 :

$$\Delta W51 = \frac{3211 - 3240}{3240} + \frac{22802 - 21198}{21198} = +7,6\%$$

- Variation pour la semaine W52 :

$$\Delta W52 = \frac{5112 - 4278}{4278} + \frac{24951 - 24016}{24016} = +23,0\%$$

Variation globale

À ce stade, nous pouvons donc calculer la variation globale de besoin de distribution entre la date de commande et la date de livraison. On calcule alors la moyenne pondérée des variations de chaque semaine (pondérée par les valeurs du BD actualisées et considérées en réalités, c'est-à-dire les valeurs en vert dans le tableau). Pour notre exemple, voici le résultat obtenu :

$$\text{Variation du besoin de distribution} = \frac{(6,8\% \times 22708) + (7,6\% \times 22802) + (23,0\% \times 24951)}{22708 + 22802 + 24951} = +12,8\%$$

Chapitre 5

Deux méthodes de détermination des causes de non-respect des délais

Nous avons présenté dans le chapitre précédent de manière détaillée le calcul de variation de chacun des paramètres dans le cadre de l'exemple d'une commande. L'algorithme que nous avons programmé, et dont le mode d'emploi est présent en annexe, permet de réaliser ces calculs pour l'ensemble des commandes pour lesquelles les variations sont calculables. Désormais en disposition de ces données de variation, nous devons maintenant en produire une analyse afin de déterminer les paramètres prédominants à l'origine du non-respect des délais de livraison annoncés.

5.1 Méthode statistique

5.1.1 Arbre de décision

Afin de déterminer l'origine du manquement au respect des délais de commande, nous avons développé un premier algorithme basé sur un arbre de décision, présenté ci-dessous.




FIGURE 5.1 – Arbre de décision développant la structure de notre algorithme statistique

Tout d'abord, l'arbre de décision considère les commandes pour lesquelles le délai de livraison annoncé n'est pas respecté. Si c'est le cas, l'algorithme va vérifier que cette modification du délai correspond bien à un changement de visibilité. Si la visibilité n'a pas changé alors que le délai n'est pas respecté, cela signifie alors que la raison de ce non-respect de délai est un manquement au principe de First In First Out (l'ordre d'arrivée des commandes n'a donc pas été respecté).

En revanche, si la visibilité a été modifiée, cela peut provenir d'une modification d'un des trois critères suivants ; PDL, besoin de distribution ou forecast. Comme on peut le voir dans l'arbre de décision, la variation de chaque critère a une certaine origine. Par exemple, une modification du PDL peut résulter d'une pénurie de matières premières ou de limites de capacité, une variation du besoin de distribution peut être dû à une nouvelle demande importante de la part d'un client et un changement de forecast peut résulter d'une évolution des prévisions de ventes, pouvant se produire en raison d'un changement de stratégie ou de la saisonnalité. Enfin, si la visibilité a été modifiée sans qu'aucun autre paramètre n'évolue, cela peut s'expliquer par une erreur dans le calcul de la visibilité ou par un bug logiciel.

Le fonctionnement de l'algorithme est le suivant : pour chaque commande, il s'agit de suivre le chemin de cet arbre de décision pour déterminer la raison expliquant une date de livraison inexacte. Ainsi, les différentes cases vertes correspondent à des points d'arrêt de notre algorithme. En généralisant ce processus à l'ensemble des commandes, il est alors possible de déterminer une répartition des origines en pourcentages entre les différentes options exposées dans cet arbre de décision.

Cependant, nous avons à cette étape fait face à deux problématiques :

- Que considère-t-on comme une variation d'un paramètre, c'est-à-dire à partir de combien de pourcentages de variation peut-on considérer que la modification est déterminante ?
- Dans quel ordre faut-il regarder les éventuelles variations de paramètres ?

5.1.2 Détermination des seuils

Premièrement, concernant la considération ou non des variations, nous avons opté pour l'utilisation de seuils. Ainsi, pour chaque paramètre, il existe un seuil fixe à partir duquel la variation du paramètre est non négligeable et même déterminante de l'origine du non-respect du délai de livraison. Toutefois, la détermination de ces seuils nécessite une véritable analyse statistique. En effet, en choisissant des seuils arbitraires différents, on obtient des résultats très éloignés !

Par conséquent, nous avons fondé notre analyse statistique sur des considérations simplistes que sont les moyennes et les écarts-types. À partir des variations des différents paramètres, l'algorithme développé permet d'obtenir les histogrammes empiriques de variation pour chaque paramètre. En fonction des valeurs de moyenne et d'écart-type de chacun, l'algorithme détermine alors les valeurs seuils respectives.



Comme on peut le voir sur les histogrammes suivants, les seuils choisis sont donc :



VISIBILITÉ : seuil = moyenne - écart-type

PLAN DE LIVRAISON : seuil = moyenne - écart-type

BESOIN DE DISTRIBUTION : seuil = moyenne

FORECAST : seuil = moyenne





5.1.3 Impact de l'ordre de considération

La seconde considération de notre méthode statistique par arbre de décision correspond à l'ordre de chaque paramètre. En effet, les cases vertes étant des points d'arrêt de l'algorithme, l'ordre de considération des paramètres joue un rôle majeur dans la répartition des origines des délais. Par exemple, pour une commande telle que la variation de forecast est supérieure au seuil associé au forecast et telle que la variation de PDL est supérieure au seuil associé au PDL, alors si l'arbre de décision est tel que celui sur la figure, l'algorithme va conclure que la raison du non-respect du délai pour cette commande est le PDL (car vérifié avant le forecast). En revanche, dans une autre configuration d'arbre de décision où le forecast est vérifié en amont du PDL, l'algorithme attribuerait le manquement du délai au forecast.

Ainsi, nous avons réalisé notre étude à travers 2 arbres de décision :

- Visibilité - PDL - Besoin de distribution - Forecast (voir schéma ci-dessus)
- Visibilité - Forecast - PDL - Besoin de distribution

Les différents résultats obtenus et les conclusions que nous en tirons sont présentés dans les rubriques suivantes.

5.2 Méthode de clustering

Cependant, en raison de ces différentes considérations face à la méthode statistique, nous avons déterminé une autre méthode permettant de s'affranchir de ces hypothèses réductrices : la méthode de clustering.

Cette idée de méthode nous est parvenue lorsque, dans la phase d'exploration et de visualisation des résultats intermédiaires (les variations des paramètres pour chaque commande), nous avons affiché simultanément sur un graphe, pour les commandes dont la visibilité avait varié, les variations de forecast, PDL et besoin de distribution. Alors, des groupes distincts de points sont apparus et l'idée du clustering nous est venue : peut-être que ces groupes de points correspondent à une certaine cause de retard.




FIGURE 5.2 – Variations de PDL, forecast et besoin de distribution pour les commandes retardées

En effet, le clustering (ou segmentation) est une technique d'analyse de données utilisée pour regrouper des objets ou des observations en groupes (appelés clusters) de telle sorte que les objets dans le même groupe soient plus similaires entre eux qu'à ceux des autres groupes.

De plus, nous avons trouvé judicieux d'appliquer une méthode de clustering pour différentes raisons :

1. Il s'agit d'une méthode automatique, où les résultats fournis sont uniquement dépendants du choix de la méthode de clustering et n'impliquent ensuite aucun choix de la part de l'utilisateur ;
2. Les résultats sont facilement interprétables et visualisables.

5.2.1 Choix de la méthode Density-Based Spatial Clustering of Applications with Noise

Il existe de nombreuses méthodes de clustering ; le choix de la méthode la plus adaptée dépend de la nature des données, de l'objectif du clustering et des ressources disponibles.

La méthode la plus populaire reste le K-means (ou méthode des K-moyennes) : elle consiste à initialiser un nombre k de centres de clusters, puis à attribuer chaque point de données au centre le plus proche. Les centres sont ensuite mis à jour en calculant la moyenne des points de données qui leur sont attribués. Ce processus est répété jusqu'à ce que la convergence soit atteinte.

K-means est particulièrement efficace pour regrouper des données numériques qui présentent des clusters bien distincts et séparés par des espaces vides (pertinent dans notre cas). Cependant, K-means suppose que les clusters ont une forme approximativement sphérique. Si les clusters ont des formes plus complexes, K-means peut ne pas les identifier correctement.

Ainsi, dès les premiers essais, nous avons remarqué que la méthode des K-means ne serait pas pertinente car elle ne permettait pas de rendre compte de ce qu'il se passait au sein de nos données, dont les clusters ont des formes complexes. Par conséquent, nous nous sommes penchés sur une méthode capable de rendre compte de ces formes géométriques singulières.

La méthode Density-Based Spatial Clustering of Applications with Noise (DBSCAN) identifie les clusters en recherchant les zones de densité élevée dans les données. Ainsi, DBSCAN peut détecter des clusters de formes arbitraires et complexes. Les premiers essais se sont montrés concluants et nous ont donc poussés à implémenter cette méthode, et à l'adapter au mieux à notre situation.

5.2.2 Fonctionnement et implémentation de la méthode DBSCAN

Tout d'abord, il est nécessaire d'explicitier qu'il existe deux grandes classes d'algorithmes de clustering : les algorithmes supervisés et les algorithmes non supervisés. Dans le cas supervisé, on part du principe que l'on connaît déjà le nombre de clusters dans notre jeu de données, alors que dans le cas non supervisé, l'algorithme va trouver le nombre de clusters optimal qui est le plus adapté aux données. Or, DBSCAN est un algorithme non supervisé : ceci ne correspond pas à nos attentes, car nous attendons forcément quatre classes différentes en retour à notre algorithme : les raisons du retard de chaque commande (forecast, PDL, besoin de distribution

et autre variation). Ainsi, nous incluerons l'algorithme DBSCAN dans un programme plus complexe pour s'affranchir de ce problème.

DBSCAN fonctionne de manière itérative en explorant les données et en identifiant les clusters denses. Il s'appuie sur deux paramètres clés :

- Rayon de voisinage (*eps*) : Ce paramètre définit la taille de la zone de voisinage autour de chaque point de données. Pour deux points P_1 et P_2 , si $d(P_1, P_2) \leq eps$, alors les deux points sont considérés comme voisins. Une valeur plus petite d'*eps* conduit à des clusters plus petits et plus nombreux, tandis qu'une valeur plus grande d'*eps* conduit à des clusters plus grands et moins nombreux.
- Nombre minimum de points par cluster (*MinPts*) : Ce paramètre détermine le nombre minimum de points de données requis dans le voisinage d'un point pour qu'il soit considéré comme un point central. Une valeur plus grande de *MinPts* conduit à des clusters plus denses et moins nombreux, tandis qu'une valeur plus petite de *MinPts* conduit à des clusters plus lâches et plus nombreux.

L'algorithme DBSCAN fonctionne selon les étapes suivantes :

1. Marquer les points non visités : initialement, tous les points de données sont marqués comme non visités.
2. Identifier les points centraux : sélectionner un point non visité, et vérifier qu'il a au moins *MinPts* voisins dans un rayons *eps*.
3. Créer un cluster à partir d'un point central aléatoire et parcourir les points centraux voisins de proche en proche :
 - Un nouveau point est ajouté au cluster si $d(P_1, P_2) \leq eps$
 - Sinon, on initialise un nouveau cluster.
4. Parcourir les points frontière et les ajouter à leur cluster respectif ; si pour tous les clusters définis, $d_{min}(cluster, P_{frontiere}) > eps$, le point est considéré comme du bruit.




FIGURE 5.3 – Fonctionnement du programme DBSCAN

Enfin, maintenant que nous avons défini l'outil utilisé, nous pouvons nous pencher sur son implémentation : deux subtilités sont à prendre en compte. Premièrement, la nécessité de régler au mieux les paramètres *MinPts* et *eps* à chaque utilisation de l'algorithme global nous a poussé à utiliser le score *silhouette*. Celui-ci quantifie la qualité de la classification : ainsi, obtenir la meilleure classification revient à maximiser le score *silhouette* en faisant varier les paramètres de l'algorithme DBSCAN. Deuxièmement, nous avons ajouté la contrainte sur le nombre de clusters souhaités (4). Ainsi, pour un ensemble de couples (*MinPts*, *eps*) :

1. L'algorithme réalise une classification par DBSCAN.
2. Si le nombre de clusters vaut 4 :
 - Le score *silhouette* est calculé et comparé à la précédente valeur enregistrée. Si le score est meilleur, on sauvegarde les paramètres qui ont permis cette classification, on passe au prochain couple (*MinPts*, *eps*) et on reprend à l'étape 1.

Chapitre 6

Résultats

6.1 Résultats obtenus avec la méthode statistique

Dans le cadre de notre étude sur le produit SKU M46203, les seuils obtenus par la méthode statistique sont les suivants :

- Visibilité : 54%
- Forecast : 1%
- PDL : 1%
- Besoin de distribution : 15%

Les résultats obtenus par le premier arbre de décision sont les suivants :

Visibilité - PDL - Besoin de distribution - Forecast




FIGURE 6.1 – Causes des délais de livraison incorrects avec la méthode statistique (arbre de décision 1)

Les résultats obtenus par le deuxième arbre de décision sont les suivants :

Visibilité - Forecast - PDL - Besoin de distribution




FIGURE 6.2 – Causes des délais de livraison incorrects avec la méthode statistique (arbre de décision 2)

On remarque alors que la forme de l'arbre de décision a en effet un impact crucial sur les résultats obtenus.

6.2 Résultats obtenus avec la méthode des clusters

Avec la méthode de clustering, les clusters obtenus sont les suivants :




FIGURE 6.3 – Clustering avec DBSCAN

On peut alors déterminer les pourcentages d'origine du non-respect des délais de livraison :




FIGURE 6.4 – Causes des délais de livraison incorrects avec la méthode des clusters

On remarque alors que les résultats de cette méthode sont proches de ceux obtenus avec la méthode statistique utilisant l'arbre de décision 2.

Chapitre 7

Conclusion

7.1 Interprétation des résultats

La méthode des clusters, ayant une logique très différente de celle statistique, donne des résultats similaires et permet de valider la méthode statistique avec un certain ordre dans l'arbre de décision. De plus, l'algorithme dans son ensemble s'avère plutôt efficace : le temps d'exécution pour l'ensemble des commandes du SKU M46203 est de **7min 24s**.

On remarque d'après notre analyse que bien que la fiabilité de production soit clé dans les résultats (PDL et besoin de distribution), les changements stratégiques (forecast) ont aussi un impact non négligeable. C'est en effet l'origine du non-respect des délais pour 1/4 des commandes ! Il apparaît donc nécessaire de prévenir les clients quand il y a des changements stratégiques.

Par ailleurs, il est essentiel de garder en tête que le choix de l'ordre des critères soulève des questions : sur qui rejeter la faute ? Sur l'industriel (PDL) ? Sur la stratégie (forecast) ? La méthode des clusters permet de s'affranchir de ces décisions.

Enfin, les quatre critères ne sont pas indépendants. Par exemple, si le PDL a changé, dans quel cas est-ce à cause du changement de besoin de distribution ? Il faudrait faire des boucles de boucles dans notre algorithme... mais on ferait alors face à un problème de complexité et de rapidité d'exécution.

7.2 Perspectives

Il existe encore certaines pistes possibles pour faire suite à notre projet :

- Réduire de nouveau le temps d'exécution du code ;
- Faire tourner l'algorithme pour des SKU différents afin d'éventuellement généraliser les conclusions à l'ensemble des produits de la marque ;
- Réaliser cette même analyse sur un produit saisonnier, avec les particularités qui en découlent.

Chapitre 8

Remerciements

Nous exprimons notre gratitude à nos tuteurs pour leur aide et leur soutien inestimables tout au long du projet. Du côté de Louis Vuitton, nous adressons nos sincères remerciements à Nicolas Schnell et Nabil Benmansour, qui nous ont chaleureusement accueillis dans leurs bureaux et ont généreusement pris le temps de nous expliquer la chaîne d’approvisionnement de la maison. Leur disponibilité et leur réactivité nous ont permis d’entrer dans l’univers du luxe en alliant convivialité et découvertes. Nous tenons également à remercier chaleureusement notre tuteur CentraleSupélec, Quentin Thuillier, pour son accompagnement et son dynamisme au cours de ces derniers mois. Son expérience de consultant nous a apporté un regard extérieur qui a largement contribué à la réussite de ce projet.

Chapitre 9

Annexe – mode d’emploi

Importation des fichiers nécessaires

Nous avons besoin de différentes données pour effectuer le calcul final donnant les pourcentages des raisons des différents retards :

- Le fichier des commandes ;
- Le fichier d’archives ;
- Le fichier avec les données sur l’ensemble des magasins.

```
from datetime import datetime, timedelta
import pandas as pd
import re
import matplotlib.pyplot as plt
import seaborn as sns
from mpl_toolkits.mplot3d import Axes3D

# Renseigner les noms des fichiers pour accéder aux données.
file_path_commandes = 'Extract ALL_Datalake.xlsx'
file_path_archives='Extract ALL_Archive.xlsx'
file_path_store='STORE.xlsx'

# Chargement des fichiers
df_commandes = pd.read_excel(file_path_commandes, sheet_name='KBRW_ORDER_LINE')
#df_PDL=pd.read_excel(file_path_archives,'PDP_PDL_QTY_ARCHIVE',header=None, engine='openpyxl')
df_PDL=pd.read_excel(file_path_archives,'PDP_PDL_QTY_ARCHIVE')
df_archives_forecast=pd.read_excel(file_path_archives,'ARCHIVE_FORECAST_EXPORTED_WEEK')
df_archives_besoin_distrib=pd.read_excel(file_path_archives,'AN_APP010_EXP_NEED_ARCHIVE')
df_magasins=pd.read_excel(file_path_store,sheet_name='STORE')
df_archives_visibilite = pd.read_excel(
    file_path_archives, sheet_name='AN_APP031_TO_BE_SHIPPED_ARCHIVE')
```

FIGURE 9.1 – Cellule de code correspondant à l’importation des fichiers

Les différentes feuilles importées dans l’environnement python seront sélectionnées automatiquement (pré-renseigné par nos soins). Cependant, il est nécessaire de remplacer les noms des fichiers par ceux sur votre machine : il y a file_path_commandes, file_path_archives, et file_path_store.

Nettoyage des données

De manière automatique, seules les commandes pertinentes seront conservées. Un résultat intermédiaire sera fourni : un fichier excel Commandes_filtrees.xlsx regroupant les commandes gardées est créé.

Calcul des variations

Les variations de la visibilité, du PDL, du besoin de distribution et du forecast sont faites à partir de fonctions définies dans quatre cellules différentes. Il suffit d’exécuter successivement ces cellules afin de rendre les différentes fonctions prêtes à l’exécution.

Le calcul le plus long du programme sera fait au moment du calcul de la variation de l’ensemble des paramètres. Il a lieu dans la cellule *Calcul des variations pour l’ensemble des commandes*. En plus de définir un

tableau `df_r` avec les résultats (qui sera réutilisé par la suite), le code crée un nouveau fichier excel intermédiaire présentant le calcul des variations des quatre paramètres (uniquement lorsqu'ils sont tous calculables).

Statistiques

Avant tout, par curiosité, mais aussi car ces résultats sont intéressants et exploitables, nous avons affiché une matrice de corrélation entre les différentes variations et les jours de retard des différentes commandes.

Ensuite, la cellule donnant les résultats pour la méthode statistique doit juste être exécutée sans modifications. Un fichier excel est alors téléchargeable avec les résultats de cette première méthode.

Clustering

La partie clustering est divisée en trois cellules différentes :

1. Le calcul des paramètres optimaux du modèle DBSCAN ainsi que les clusters associés.
2. Une visualisation graphique sur trois axes des différentes variations avec pour chaque point (correspondant à une commande) une couleur l'identifiant à un cluster.
3. Un calcul des différents pourcentages attribuant à chaque facteur une part de responsabilité et l'exportation sur un fichier excel des résultats finaux.

Les deux premières cellules peuvent être lancées en premier afin d'obtenir une première idée des résultats. La seule subtilité du programme et de la méthode de clustering intervient ici : il faut attribuer à chaque numéro de cluster la raison associée. Par exemple, le cluster 0 correspond aux commandes arrivées en retard car le PDL a varié.

```
resultats_tri=df_r[['ORDER_ID', 'variation de forecast', 'variation de BD', 'variation de PDL', 'clusters']]

autre=-1
PDL=0
BD=1
forecast=2

# Assigner
conditions = [
    (resultats_tri['clusters'] == PDL),
    (resultats_tri['clusters'] == BD),
    (resultats_tri['clusters'] == forecast),
    (resultats_tri['clusters'] == autre)
]
valeurs = ['PDL', 'BD', 'Forecast', 'Autre']

# Utiliser np.select pour attribuer les valeurs en fonction des conditions
resultats_tri['Facteur'] = np.select(conditions, valeurs, default='')

counts = resultats_tri['Facteur'].value_counts()

# Calculer le pourcentage d'apparition de chaque valeur
percentages = (counts / resultats_tri.shape[0]) * 100

# Afficher les résultats
print("Pourcentage d'apparition de chaque valeur dans la colonne 'facteur':")
print(percentages)

resultats_tri.to_excel('Resultats.xlsx', index=False)
```

FIGURE 9.2 – Cellule de code correspondant à la finalisation des résultats

Il faut changer les lignes 1 à 5 en mettant le bon numéro de cluster avec la bonne cause. Ceci peut être fait soit graphiquement (non recommandé, car difficile à repérer avec la perspective) soit en lançant cette dernière cellule afin de récupérer le document excel *Resultatstextunderscoreclustering.xlsx*. En ouvrant le document excel, on peut faire le lien cause - numéro par élimination en utilisant quelques commandes.